Luis Inga Rivera

AI Engineer | Desarrollador Full-Stack | Cloud y DevOps

Madrid, España | lair60@yahoo.es | +34 637 229 134 | +44 7821 232 546

lair60.github.io | github.com/lair60 | linkedin.com/in/lair60 | AI Engineering Lab (demo en vivo)

Resumen profesional

AI Engineer y desarrollador full-stack con más de 15 años de experiencia creando y operando software en producción. Enfoque reciente: productos basados en LLM, con orquestación multimodelo (Gemini, OpenAI, DeepSeek), streaming en tiempo real, comprensión de documentos y generación aumentada por recuperación (RAG), entregados de extremo a extremo, desde la arquitectura hasta el despliegue en la nube. AWS Certified Generative AI Developer – Professional y AWS Certified DevOps Engineer – Professional. Trayectoria previa en desarrollo empresarial y front-end (SAP Fiori, Java, JavaScript) en Reino Unido y España.

Competencias clave

IA / LLM: Orquestación de LLM (Gemini, OpenAI, DeepSeek), RAG, búsqueda híbrida, embeddings, pgvector, modelos autoalojados (Ollama, Qwen), streaming de respuestas, evaluación

Backend: Python, FastAPI, Celery, Redis, WebSockets, APIs REST, PostgreSQL, MongoDB, Supabase, Java, Node.js

Cloud y DevOps: AWS, Oracle Cloud (OCI), Docker, Linux, Git

Front-end y móvil: React Native (Expo), JavaScript, TypeScript, SAP Fiori / UI5, HTML, CSS

Lenguajes de programación: Python, Java, JavaScript, TypeScript, C++, PHP, SQL

Experiencia profesional

(03/2025 - 09/2026) **Full Stack Developer (AI Engineering) – Zinga Education S.L.**

Plataforma de aprendizaje con IA para web, iOS y Android: comprensión de documentos, generación de cuestionarios y tutoría en tiempo real con varios LLM.

- **Orquestación multi-LLM:** Diseñé una capa de IA unificada sobre tres proveedores de LLM (Gemini, OpenAI y DeepSeek) para comprensión de documentos, generación de cuestionarios y tutoría de matemáticas en tiempo real, con limitación de peticiones y gestión de errores para mantener una alta disponibilidad y controlar el gasto en tokens.
- **Backend asíncrono:** Construí el backend con FastAPI, Celery y Redis para que las tareas largas (extracción de texto, llamadas a LLM) se ejecuten fuera del ciclo de petición, con reintentos, timeouts y backoff exponencial.
- **Streaming en tiempo real:** Envié las respuestas de los LLM a iOS, Android y web mediante WebSockets nativos, con recuperación de mensajes (Redis Pub/Sub) y reconexión automática, de modo que el usuario no pierde una respuesta si se corta la conexión.
- **Pipeline de documentos:** Procesé los documentos subidos por los usuarios desde almacenamiento de objetos en la nube, con workers concurrentes y operaciones idempotentes que evitan trabajo duplicado.
- **Entrega multiplataforma:** Entregué una única base de código Expo (React Native) para tres plataformas (web, iOS y Android), con autenticación y pagos de paquetes de créditos por dos canales (Stripe en web y compras integradas nativas en móvil).
- **Responsabilidad de extremo a extremo:** Arquitectura, implementación, despliegue y operación en Oracle Cloud (Load Balancer, Object Storage).

Tecnologías: Gemini, OpenAI, DeepSeek, FastAPI, Celery, Redis, WebSockets, MongoDB, Supabase, OCI (Load Balancer, Object Storage), React Native (Expo), Stripe, compras integradas (in-app).

(04/2016 - 08/2024) **Front End Developer – Capita PLC (Reino Unido)**

- Migré una aplicación Java Web Dynpro desde sistemas heredados a aplicaciones SAP Fiori.
- Construí nuevas interfaces siguiendo las guías de diseño de SAP Fiori (list reports, object pages, flexible-column layouts) y definí modelos OData con binding unidireccional y bidireccional.
- Desplegué aplicaciones Fiori desde SAP Web IDE / BAS en SAP Launchpad.
- Identifiqué la causa raíz (una mala configuración durante una migración de sistemas) de un fallo que afectaba a miles de usuarios en Alemania, y lo resolví.
- Mejoré la experiencia de usuario de sistemas heredados corrigiendo errores y optimizando código legacy.

Tecnologías: UI5, OData v2, CDS views, S/4HANA, Java, JSP, jQuery, TypeScript, XML, HTML, CSS, Dojo, Git.

(11/2015 - 03/2016) **Full Stack Developer (Contractor) – ParkwayLogic (Reino Unido)**
Desarrollo front-end y back-end de un sistema de trading. AngularJS, jQuery, Ajax, Bootstrap, PHP, MySQL, Linux, AWS.

(04/2015 - 06/2015) **Front End Developer – SuperAwesome (Reino Unido)**
Páginas web responsive para empresas de publicidad. JavaScript, jQuery, Ajax, JSON, HTML, CSS, Bootstrap, Git.

(03/2014 - 01/2015) **Front End Developer – Lytespark (Reino Unido)**
Servicios de videoconferencia con WebRTC: extensión de Chrome para compartir pantalla, soporte de la API REST y compatibilidad entre navegadores (Chrome, Firefox, Opera, Safari, IE). JavaScript, Node.js, MongoDB, REST, Git.

(10/2013 - 01/2014) **Analista – Alten (España)**
Proyecto Gas Natural: coordinación de equipos funcionales y de desarrollo en la migración de una aplicación web; validación de requisitos y comprobaciones de datos con SQL. Java, SQL, Redmine, SharePoint, Subversion.

(10/2010 - 08/2012) **Analista / Back-end Developer – Everis (España)**
AXA (seguros de coche): análisis de interfaces y software de pruebas para un nuevo sistema de gestión de pólizas. MAUI-Telefónica: diseño funcional y validación de un nuevo portal estandarizado. Java EE, Python, UML, SQL, Jira.

(10/2007 - 07/2010) **Analista / Developer – Dynasty Technology Group (España)**
Software para dispositivos bancarios (pinpads, cajeros, lectores de cheques, impresoras) según el estándar JXFS en Linux y Windows. Java, C++, JUnit, JNI, Linux.

Proyectos

AI Engineering Lab – sistema RAG autoalojado lair60.github.io/lab

- Preguntas y respuestas sobre documentos con recuperación aumentada: recuperación híbrida (pgvector + búsqueda de texto completo de PostgreSQL), embeddings multilingües y modelos Qwen servidos con Ollama en CPU ARM de Oracle, con respuestas en streaming y un modo técnico que muestra fragmentos, puntuaciones y prompts.
- Aspectos de producción: ingesta asíncrona (FastAPI, Celery, Redis), aislamiento de datos por sesión con borrado automático, límites de uso, cuotas, protección anti-bots con Cloudflare Turnstile e interruptor de emergencia.
- Evaluación: ajuste del troceado, la recuperación y el modelo con un conjunto de 23 preguntas (95 % de acierto en la recuperación; 0 de 4 preguntas sin respuesta contestadas con información inventada).

Formación académica

Máster en Ingeniería Informática – Universidad Complutense de Madrid, España | 10/2008 - 09/2013

Certificaciones

AWS Certified Generative AI Developer – Professional (10/2026) Credly
AWS Certified DevOps Engineer – Professional (07/2020) Credly
SAP Certified Development Associate – SAP Fiori Application Developer (03/2018) Credly

Idiomas

Inglés (Profesional) | Español (Nativo)